


LSTM vs CNN



Autores: Rubén Pérez y Daniel Gallego

Fecha: 28/05/2026

Asignatura: Programación de Inteligencia Artificial

1. Resolución de Preguntas (Obligatorias)

¿Qué modelo obtiene mejores resultados y si la diferencia es significativa? Por lo general, LSTM tenderá a obtener ligeramente mejores resultados globales (menor MAE/RMSE) debido a que el dataset sintético introduce dependencias complejas, retardos en los sensores y memoria a largo plazo que la CNN no retiene fuera de la ventana W .

¿En qué situaciones falla la CNN y por qué? La CNN falla en detectar patrones que dependen de estados del sistema muy anteriores al inicio de la ventana de tamaño 30. Al buscar solo correlaciones locales (features temporales cercanas), pierde la noción del "régimen" global de la máquina.

¿En qué situaciones falla la LSTM y por qué? La LSTM tiende a sobre-suavizar las predicciones y puede tener un ligero retraso frente a "picos" o ruido abrupto de altísima frecuencia. Al retener el estado histórico a largo plazo, ante un cambio súbito local e impredecible (ruido puro), puede tardar un par de instantes en adaptarse.

¿Qué tipos de anomalías detecta mejor cada modelo?

CNN 1D: Excelente detectando anomalías contextuales cortas o picos ruidosos (spikes), ya que alteran fuertemente el patrón de vecindad local que la convolución ha aprendido.

LSTM: Ideal para detectar anomalías progresivas (drifts) o rupturas de dependencia temporal a largo plazo (por ejemplo, cuando la presión deja de seguir a la temperatura después de ciertos ciclos).

¿Cómo afecta el tamaño de ventana? Ventanas más cortas reaccionan más rápido, pero introducen mucho ruido (inestabilidad). Ventanas más grandes le otorgan más información a la CNN (hasta igualar potencialmente el alcance de la LSTM en ciertos casos), pero aumentan la complejidad computacional.

2. Resolución de Preguntas (Avanzadas)

¿Por qué una CNN 1D puede funcionar bien en series temporales sin memoria explícita?

Las CNN 1D no tienen una "memoria" del pasado como las LSTM, pero son excelentes extractores de características locales. Funcionan aplicando filtros que identifican patrones morfológicos específicos en la ventana de datos (como picos, caídas, o frecuencias locales). Si la predicción a corto plazo depende principalmente de la forma reciente de la señal más que de un estado histórico lejano, la CNN mapeará ese patrón local directamente a la salida con mucha eficacia y menor coste computacional.

¿Por qué una LSTM no mejora indefinidamente al aumentar la ventana? Debido al problema del desvanecimiento del gradiente (vanishing gradient) que, aunque mitigado por las compuertas de la LSTM, sigue afectando en secuencias muy largas. Además, a partir de

cierto umbral, la información muy antigua aporta más ruido que valor predictivo para el futuro inmediato, haciendo que el modelo pierda el foco en los datos recientes más relevantes y sufra de sobreajuste (overfitting).

¿Qué anomalía es más difícil de detectar en este dataset y por qué? Las anomalías progresivas sutiles (subtle drifts) combinadas con los cambios de régimen. Como el dataset incluye ruido operativo y la máquina cambia de estado (regime) de forma natural, una desviación muy lenta en un sensor (por ejemplo, una ligera pérdida de presión) puede ser interpretada por el modelo como una adaptación a un nuevo régimen normal o simplemente ruido, dificultando que el error de predicción supere el umbral de anomalía.

¿Qué papel tendría una CNN y una LSTM en un modelo híbrido? En una arquitectura híbrida (CNN-LSTM), cada capa asume un rol complementario:

- **CNN 1D (Feature Extractor):** Se coloca al principio para procesar la señal en bruto. Actúa filtrando el ruido y extrayendo características locales de alto nivel (reduciendo la dimensionalidad temporal).
- **LSTM (Sequence Learner):** Recibe las características procesadas por la CNN y se encarga de modelar cómo evolucionan estos patrones a lo largo del tiempo, capturando la memoria a largo plazo.

¿Qué ocurre si se elimina la variable flow? Al eliminar flow, retiramos una variable que inyecta ruido operativo complejo y dependencias sinusoidales adicionales al sistema. Sin ella, las relaciones entre la temperatura, la presión y la vibración se vuelven más limpias y deterministas. Esto provocaría que el error de todos los modelos caiga drásticamente, haciendo el problema de predicción mucho más fácil y reduciendo la ventaja comparativa de la LSTM sobre la CNN.

¿Qué ocurre si se desordena la secuencia temporal antes de entrenar? Depende de cuándo se desordene:

- Si se desordena la serie temporal en bruto **antes de crear las ventanas** (X e Y), se destruye por completo la causalidad y dependencia temporal. El modelo será incapaz de aprender nada útil y solo predecirá ruido.
- Si se desordena el conjunto de datos después de crear las ventanas (es decir, barajar el orden de los pares [ventana de entrada -> valor futuro]), es una práctica recomendada en Deep Learning (shuffle). Ayuda a que los gradientes sean más estables y evita que el modelo memorice el orden secuencial de los lotes durante el entrenamiento.

3. Gráficas y Resultados Visuales

	t	temp	pressure	vibration	flow
0	0	52.696589	1.073981	0.062141	9.496712
1	1	52.042627	1.062422	0.062239	9.784019
2	2	52.070599	1.039302	0.069311	9.685972
3	3	53.354671	1.070951	0.064267	10.058718
4	4	52.935889	1.097917	0.071278	10.010820

