


Redes Neuronales



Autores: Rubén Pérez González

Fecha: 22/04/2026

Asignatura: Sistemas de Aprendizaje Automático (IA)

Parte 2 — Entrenar modelos base (ML Clásico)

Resultados obtenidos:

```
Accuracy RF: 0.9649122807017544
Accuracy SVM: 0.9824561403508771
Accuracy Regresión Logística: 0.9736842105263158
```

Accuracy RF: 0.9649

Accuracy SVM: 0.9824

Accuracy Regresión Logística: 0.9736

1. ¿Cuál de los dos modelos clásicos ha funcionado mejor? El modelo que mejor rendimiento ha mostrado es el SVM (Support Vector Machine) con un accuracy de 0.9824. Ha superado tanto a la Regresión Logística como al Random Forest en este conjunto de datos específico tras la estandarización.
2. ¿Crees que estos modelos son capaces de detectar relaciones no lineales complejas en este dataset? Sí. El Random Forest, al ser un conjunto de árboles de decisión, maneja de forma natural las no linealidades mediante particiones del espacio de características. Por su parte, el SVM (que utiliza por defecto el kernel RBF en scikit-learn) proyecta los datos a dimensiones superiores para encontrar fronteras de decisión no lineales complejas.

Parte 3 — Implementar la Red Neuronal (Keras)

Resultados obtenidos:

```
Accuracy RED NEURONAL: 0.9649122953414917
```


Accuracy RED NEURONAL: 0.9649

1. ¿Ha superado la Red Neuronal a los modelos clásicos (RF/SVM)? No. En este caso, la Red Neuronal ha obtenido un accuracy de 0.9649, el cual es idéntico al del Random Forest, pero inferior al del SVM (0.9824) y al de la Regresión Logística (0.9736). Esto indica que para este tamaño de dataset, un modelo clásico bien ajustado puede ser igual o más efectivo que una red neuronal.
2. ¿Qué función de activación hemos usado en las capas ocultas y por qué? Se ha utilizado la función ReLU (Rectified Linear Unit). Es la más común en las capas ocultas porque permite a la red aprender relaciones no lineales, es computacionalmente eficiente y ayuda a evitar el problema del desvanecimiento del gradiente, facilitando un entrenamiento más rápido.

3. ¿Qué indica el hecho de usar sigmoid en la última capa? La función Sigmoid transforma la salida de la última neurona en un valor entre 0 y 1. Esto permite interpretar el resultado como una probabilidad, lo cual es fundamental en problemas de clasificación binaria como este (determinar si un tumor es benigno o maligno).

Parte 4 — Análisis y Matriz de Confusión

Resultados obtenidos:



1. Observando la matriz, ¿qué tipo de error comete más la red: Falsos Positivos o Falsos Negativos? Analizando la matriz de confusión, se observa que la red comete exactamente el mismo número de errores en ambas categorías: 2 Falsos Positivos (predijo benigno cuando era maligno) y 2 Falsos Negativos (predijo maligno cuando era benigno). El error está equilibrado.

2. ¿Qué pasaría con el entrenamiento si eliminamos la función de activación relu de las capas ocultas? Si se eliminan las activaciones no lineales, la red se comportaría como un modelo lineal simple (similar a una regresión logística), independientemente de cuántas

capas tenga. La combinación de capas lineales da como resultado otra función lineal, perdiendo la capacidad de modelar patrones complejos en los datos.

3. ¿Por qué es crítico escalar los datos (StandardScaler) antes de pasarlos por la red neuronal? Las redes neuronales utilizan el descenso del gradiente para ajustar sus pesos. Si las características tienen escalas muy diferentes, los gradientes pueden volverse inestables o demasiado grandes/pequeños, lo que dificulta o impide que el modelo converja hacia una solución óptima. El escalado asegura que todas las variables contribuyan de forma equitativa al aprendizaje.

Reflexión final

El uso de Redes Neuronales es altamente recomendable en proyectos reales que involucren datos no estructurados de gran volumen, como el reconocimiento de imágenes, procesamiento de lenguaje natural o series temporales complejas, donde el aprendizaje de características automáticas es una ventaja crítica.

Sin embargo, no las recomendaría en situaciones donde el dataset sea pequeño o tabular, ya que modelos clásicos como SVM o Gradient Boosting suelen alcanzar resultados similares o superiores con menor coste computacional. Tampoco serían la primera opción cuando la interpretabilidad total del modelo sea un requisito legal o técnico, debido a la naturaleza de "caja negra" que suelen presentar las arquitecturas profundas.